

队伍编号	903462
题号	D

基于 DRA-PSO 优化的 钢水脱氧合金化深度探究

摘 要

本文采用了双变量相关和偏相关相结合的方法得到了影响 C、Mn 收得率的主要的影响因素，在此基础上，利用多元回归预测模型对 C、Mn 的收得率进行预测，为提高预测准确率，本文又建立了基于粒子群优化的 RBF 神经网络预测模型，经检验拟合程度很高。而后通过建立基于粒子群优化的多目标优化模型，得到了合金配料方案及相应价格，实现了质量与价格的双重保障，并为炼钢厂领导写了一封建议信。

针对问题一，本文首先对数据进行了清洗，通过合金收得率的定义求得出 C、Mn 的历史收得率。而后本文运用双变量相关和偏相关相结合的方法求得影响 C 的收得率的主要因素为：钢水净重、连铸正样 C、碳化硅 (55%)，影响 Mn 的收得率的主要因素为：钢水净重，连铸正样 Mn，连铸正样 Si，连铸正样 Ceq_val，连铸正样 V_val，连铸正样 Ti_val，低铝硅铁，钒氮合金 (进口)，钒铁 (FeV50-B)，碳化硅 (55%)。

针对问题二，结合问题一得到的主要影响因素，本文在排除了多重共线性的影响下，建立了多元线性回归预测模型，对 C、Mn 收得率进行初步预测，为进一步提高预测率，本文又建立了基于粒子群优化的 RBF 神经网络预测模型，达到了较为精准的 C、Mn 收得率预测，最后对模型进行了检验，模型的拟合程度很高。

针对问题三，考虑到脱氧合金化成本优化的复杂性，本文建立了基于粒子群优化的多目标规划模型，得到了不同钢种的合金配料方案，并随机抽取了 25 组完整数据对模型进行检验，结果显示模型可在保证钢材质量的前提下，有效降低配料成本。

针对问题四，本文根据前三问探究所得的结果，为厂长写了一封建议信，在如何合理化投入合金配料，保证钢水质量前提下如何最大限度降低生产成本，以及钢铁企业竞争力的提高等方面做出了建议。

本文在对数据进行清洗的基础上，计算了 C、Mn 的历史收得率，通过双重相关分析得到了影响 C、Mn 收得率的主要影响因素，运用粒子群的优化性能，建立了基于粒子群优化的 RBF 神经网络预测模型，使得预测的准确性达到了 93.4%。而后通过建立基于粒子群优化的多目标优化模型，实现了对当前炉次合金配料的自动优化和成本控制。

关键词： 双重相关分析 粒子群算法 RBF 神经网络 多目标优化模型

目录

一、问题重述	1
1.1 问题背景及研究意义	1
1.2 问题相关信息	1
1.3 需解决的问题	1
二、问题分析	1
2.1 问题一的分析	2
2.2 问题二的分析	2
2.3 问题三的分析	2
2.4 问题四的分析	2
三、基本假设	3
四、符号说明与名词解释	3
4.1 符号说明	3
4.2 名词解释	4
五、问题一模型建立与求解	4
5.1 历史收得率的计算与求解	4
5.1.1 辩证与数据的预先处理	4
5.1.2 C 、 Mn 历史收得率的求解	5
5.1.3 合金收得率分析	7
5.2 双重关联分析模型的建立与求解	8
5.2.1 相关性分析	8
5.2.2 偏相关分析	10
5.2.3 双重相关对主要因素的确定	11
六、问题二模型的建立与求解	12
6.1 收得率预测模型的建立与求解	12
6.1.1 多元线性回归预测模型的建立	12
6.1.2 模型的检验	14
6.2 模型与算法的改进	15
6.2.1 径向基函数神经网络拓扑结构	16
6.2.2 减法聚类算法求 RBF 神经网络聚类中心	16
6.2.3 粒子群优化的 RBF 神经网络模型	17
6.2.4 模型结果及模型的检验	17
6.3 改进前后对比	19

七、问题三模型的建立与求解	19
7.1 目标优化模型的构建	19
7.2 基于粒子群优化的多目标优化模型	21
7.3 模型的求解	21
7.4 模型的检验	23
八、写给钢厂领导的一封信	24
九、模型的评价、改进与推广	25
9.1 模型的评价	25
9.1.1 模型优点	25
9.1.2 模型缺点	25
9.2 模型的改进	25
9.3 模型的推广	25
十、参考文献	26
十一、附录	27
附录 A 相关性分析	27
附录 B RBF 神经网络	27
附录 C 粒子群优化的多目标规划	29

一、问题重述

1.1 问题背景及研究意义

随着社会科技的迅猛发展,各行业对钢材质量、性能的要求不断提高,钢铁根据添加元素的不同,并采取适当的加工工艺,可获得高强度、高韧性、耐磨、耐腐蚀、耐低温、耐高温、无磁性等特殊性能.

炼钢过程中的脱氧合金化是钢铁冶炼中的重要环节,而我国目前大多数的钢铁企业,均按照不同元素的固定收得率或者是经验值,来计算各合金的加入量,效率差、准确率低.因此对脱氧合金化过程中,当前炉次的合金配料进行自动优化,以及成本的精准把控尤为重要.

1.2 问题相关信息

附件 1 给出 1716 个炼钢炉所炼制出的低合金钢的信息,其中钢号为 HRB400B 的有 1291 个,钢号为 HRB400D 的有 275 个,钢号为 HRB500B 的有 17 个,钢号为 HRB500D 的有 66 个,钢号为 20MnKA 的有 33 个,钢号为 20MnKB 的有 13 个,钢号为 Q235 的有 4 个,钢号为 Q235A 的有 7 个,钢号为 Q345B 有 10 个.

附件 2 给出了 16 种合金配料中所含元素的重量百分比,以及各合金配料每吨的价格.

1.3 需解决的问题

问题 (1): 通过附件 1 给出的低合金钢种前期的真实冶炼数据,利用合金收得率公式求解出 C 、 Mn 两种元素的历史收得率,并借助相应的分析方法,得到影响 C 、 Mn 收得率的主要因素.

问题 (2): 根据问题 1 所构建的模型,对 C 、 Mn 两种元素的收得率进行预测,并对目前的预测模型和算法进行进一步的完善与改进,以提高对 C 、 Mn 两种元素收得率的预测准确率.

问题 (3): 附件 2 中给出了不同合金配料每吨的价格,并且价格各不相同,这些合金料的选择对钢水脱氧合金化的成本有着直接的影响,利用问题 2 中对合金收得率的预测结果,以及附件 2 中的信息,建立钢水脱氧合金化成本优化模型,以达到成本的最优的目的,最后给出合金配料方案.

问题 (4): 根据前三问对钢水脱氧合金化的研究结果,为炼钢厂领导写一封建议信.

二、问题分析

此题主要研究的是钢水脱氧合金化时得元素收得率预测与所需配料成分问题,首先通过建立双重相关模型,求解得影响 C 、 Mn 收得率的主要因素,其次建立粒子群优化得 RBF 神经网络模型,预测出 C 、 Mn 元素的收得率,最后利用粒子群优化的多目标优化模型 1 得出不同钢种所需的配料,计算出成本.现对本题的三个问题分析如下:

2.1 问题一的分析

本问要求根据附件 1 中的信息, 计算出 C 、 Mn 两种元素的历史收得率. 由合金收得率的定义可知, 其就是脱氧合金化时被钢水吸收的合金元素的重量, 与加入该元素总重量之比. 但是由于数据量较为庞大, 首先需要对数据进行清洗, 排除异常值以及无用信息.

利用 C 、 Mn 的连铸正样与转炉终点之差, 与钢水净重相乘, 可以得到钢水吸收的合金元素的重量; 结合附件二中所给的各合金料自身成分的百分比, 可以计算出 C 、 Mn 两元素加入的总重量, 通过定义计算, 即可得出 C 、 Mn 两种元素的历史收得率.

接下来需要分析影响 C 、 Mn 两元素收得率的主要因素, 很显然这是一个寻求 C 、 Mn 两元素收得率与其他因素之间相关性的问题, 所以可以通过相关性分析与偏相关分析的双重分析, 进而可以确定出影响 C 、 Mn 两元素收得率的主要因素.

2.2 问题二的分析

本问要求在问题一的基础上, 对 C 、 Mn 两种元素收得率进行初步的预测. 在第一问的分析中, 本文得到了 C 、 Mn 两元素收得率与主要因素之间的相关系数, 不妨利用线性回归对 C 、 Mn 两种元素的收得率进行初步的预测.

初步预测后, 本问还要求进一步提高对两种元素收得率的预测准确率, 考虑到两种元素收得率不仅仅与时间有关, 同时还与其他因素有关, 故需要一个建立一个综合预测类模型.

显然, 单纯的 BP 神经网络所建立的收得率预测模型的性能并不是太好, 不仅误差较大, 而且收敛的精度不高, 收敛的速度也不是很快, 且容易陷入局部极小值, 不足以满足精确预测的要求, 为此需要借助粒子群对其进行优化.

2.3 问题三的分析

第三问是对钢水脱氧合金化成本的优化问题, 很明显, 可以采用目标优化模型, 但是要在保证钢水质量的同时, 将合金钢的生产成本最大限度的降低, 且可以应对不同钢种的要求, 这就要求模型具有一定的智能性, 而单纯的多目标优化模型是无法满足的.

因为本文决定利用粒子群算法对模型进行优化, 从而达到在线预测并优化投入合金的种类及数量的能力, 实现钢水脱氧合金化成本的控制.

2.4 问题四的分析

本问要求根据前三问的研究结果, 为炼钢厂领导写一封建议信, 本质上其实就是对前三问问题的一个总结性的概括, 因此本文决定利用前三问中出现的问题, 以及解决的方法思路, 为炼钢厂车间的收得率预测, 合金合理投放, 成本控制等几个方面进行讨论.

三、基本假设

1. 假设在转炉终点以及连铸正样之前，钢水的净重不发生变化.
2. 假设钢水“脱氧合金化”过程中，转炉温度不会发生改变.
3. 假设钢水“脱氧合金化”过程中，不会发生安全事故.
4. 假设炉体中的炉渣已经清理干净，不会对下一次的反应造成影响.
5. 假设钢水“脱氧合金化”过程中不受现场条件的限制.
6. 假设钢水“脱氧合金化”过程中产生的有毒物质均被安全处理.
7. 假设钢水“脱氧合金化”过程中，不会混入其他杂质.
8. 假设钢水脱氧合金化制度完善，工艺操作精细，市场运营成熟，利于钢种的销售.

四、符号说明与名词解释

4.1 符号说明

符号	意义
α	转炉终点
β	连铸正样
γ_1	氮化钒铁 (FeV55N11-A) 质量
γ_2	低铝硅铁质量
γ_3	钒氮合金 (进口) 质量
γ_4	钒铁 (FeV50-A) 质量
γ_5	钒铁 (FeV50-B) 质量
γ_6	硅铝钙质量
γ_7	硅铝合金 (FeAl30Si25) 质量
γ_8	硅铝锰合金球质量
γ_9	硅锰面 (硅锰渣) 质量
γ_{10}	硅铁 (合格块) 质量
γ_{11}	硅铁 FeSi75-B 质量
γ_{12}	石油焦增碳剂质量
γ_{13}	锰硅合金 FeMn64Si27(合格块) 质量

γ_{14}	锰硅合金 FeMn68Si18(合格块) 质量
γ_{15}	碳化硅 (55%) 质量
γ_{16}	硅钙碳脱氧剂质量
m	钢水净重
η	收得率
Δ	吸收的合金元素的重量
M	加入该元素的总重量

4.2 名词解释

1. 脱氧：向钢中加入脱氧元素，使之与氧发生反应，生成不溶于钢水的脱氧产物，并从钢水中上浮进入渣中，钢中氧含量达到所炼钢种的要求，这项工艺称为脱氧。

2. 合金化：为了调整钢中合金元素含量达到所炼钢种规格的成分范围，向钢中加入所需的铁合金或金属的操作是合金化。

五、 问题一模型建立与求解

5.1 历史收得率的计算与求解

5.1.1 辩思与数据的预先处理

关于收得率的辩思

根据合金收得率的定义可知，其就是脱氧合金化时被钢水吸收的合金元素的重量，与加入该元素总重量之比。而脱氧合金化时被钢水吸收的合金元素的重量，可以近似看作是该元素的连铸正样与转炉终点之差，与钢水净重的乘积，即：

$$\Delta = (\beta - \alpha) \cdot m \quad (1)$$

其中 β 为连铸正样， α 为转炉终点， m 为钢水净重。

当得到脱氧合金化时被钢水吸收的合金元素的重量 Δ 后，便可以得出合金的收得率公式为：

$$\eta = \frac{\Delta}{M} \quad (2)$$

其中 M 为该元素加入的总重量，其等于各合金料自身该成分的含量之和。

不难看出，连铸正样 β 、转炉终点 α 、以及钢水净重 m 的数据准确性，对脱氧合金化时被钢水吸收的合金元素的重量计算影响巨大。

数据的处理

附件 1 给出 1716 个炼钢炉所炼制出的低合金钢的信息, 对于这些中的的数据, 进行数据的清洗是不可避免的, 首先需要对其进行无用信息以及异常值的排除.

通过 SPSS 对数据的初步筛选, 本文发现转炉终点 Mn 共有 1465 组数据处于缺失状态, 同样的, 连铸正样 C 与连铸正样 Mn 也均缺失了 906 组数据. 对于这些缺失数据的信息组, 是没有办法参与合金元素收得率的计算的, 因此需要对其进行排除.

进而本文对剩下的数据进行了异常值的分析, 分析结果显示, 在排除了无用信息之后不存在异常值. 由于篇幅限制, 本文只给出转炉终点 C 和转炉终点 Mn , 在异常值寻找时的所作的箱线图.




图 1 转炉终点 C 箱线图




图 2 转炉终点 Mn 箱线图

5.1.2 C 、 Mn 历史收得率的求解

C 历史收得率的求解

由公式 (1) 可得脱氧合金化时被钢水吸收的 C 元素的重量为:

$$\Delta_C = (\beta_C - \alpha_C) \cdot m \quad (3)$$

其中 β_C 为碳元素的连铸正样, α_C 为碳元素的转炉终点, m 为钢水净重.

钒铁 (FeV50-A)	钒铁 (FeV50-B)	硅锰面	硅铝合金 FeAl30Si25
0.0031	0.0031	0.00374	0.017
硅铁 (合格块)	硅铁 (FeSi75-B)	石油焦增碳剂	FeMn64Si27(合格块)
0.0006	0.0006	0.96	0.017
FeMn68Si18(合格块)	碳化硅 (55%)	硅钙碳脱氧剂	
0.017	0.3	0.225692	

表 1 各合金料含 C 百分比

根据上表中个合金料中碳重量的百分比，可以求得加入碳元素的总重量：

$$M_C = 0.0031\gamma_4 + 0.0031\gamma_5 + 0.00374\gamma_9 + 0.014\gamma_7 + 0.0006\gamma_{10} + 0.0006\gamma_{11} + 0.96\gamma_{12} + 0.017\gamma_{13} + 0.017\gamma_{14} + 0.3\gamma_{15} + 0.225692308\gamma_{16} \quad (4)$$

最终可得到 C 的收得率公式为：

$$\eta_C = \frac{\Delta_C}{M_C} \quad (5)$$

将筛选过后的数据代入上式，最终得到了 810 组 C 元素的历史收得率，部分数据如下：

炉号	7A06878	7A06877	...	7A06062	7A06061	7A06060	平均收得率
C 收得率	0.915705	0.868818	...	0.882789	1.047336	0.928203	0.943

表 2 C 的历史收得率

Mn 历史收得率的求解

同理由公式 (1) 可得脱氧合金化时被钢水吸收的 Mn 元素的重量为：

$$\Delta_{Mn} = (\beta_{Mn} - \alpha_{Mn}) \cdot m \quad (6)$$

其中 β_{Mn} 为碳元素的连铸正样， α_{Mn} 为碳元素的转炉终点， m 为钢水净重。

硅铝锰合金球	硅锰面（硅锰渣）	FeMn64Si27(合格块)	FeMn68Si18(合格块)
0.3	0.664	0.664	0.664

表 3 各合金料含 **Mn** 百分比

根据上表中个合金料中碳重量的百分比，可以求得加入锰元素的总重量：

$$M_{Mn} = 0.3\gamma_8 + 0.664\gamma_9 + 0.664\gamma_{13} + 0.664\gamma_{14} \quad (7)$$

最终可得到 Mn 的收得率公式为：

$$\eta_{Mn} = \frac{\Delta_{Mn}}{M_{Mn}} \quad (8)$$

将筛选过后的数据代入上式，最终得到了 251 组 Mn 元素的历史收得率，部分数据如下：


炉号	7A06878	7A06877	...	7A06710	...	7A06621	7A06620	Mn 平均收得率
Mn 收得率	0.896938	0.933969	...	1.009844	...	0.936407	0.961141	0.9152

表 4 **Mn** 的历史收得率

经统计，同时可求得的 C 、 Mn 两元素历史收得率的炉号信息共有 227 组，这 227 组数据将是接下来，对影响两元素收得率主要因素的探究的主要数据依据。



5.1.3 合金收得率分析

魏春新^[1]曾指出，由于炼钢使用氩气的工艺增多，造成氩气的压力低于设计值，使钢包底吹氩排渣效果不理想，导致浸渍管罩入钢渣。因此，底吹氩气压力对合金收得率的影响主要体现在钢渣对其的影响。钢渣的主要成分是 CaO 、 SiO_2 、 MgO 、 FeO 和 P_2O_5 等，从已知氧化物标准自由焓和温度的关系可知：在温度低于 2473K 时 Al 能在很大的温度范围内使所用金属（Ca 和 Mg 除外）氧化物还原，即发生反应如下反应：





SiO₂ 的标准生成自由焓要低于 MnO 和 FeO，同理发生 (11)、(12) 反应：



SiC 颗粒在高温作用下迅速发生分解反应 (13)，分解产物部分参与脱氧反应，部分溶入钢液，起到对钢液增碳的作用，一部分碳单质会与铁单质发生反应 (14) 生成碳化铁，而另一部分则发生物理渗透：



综上所述，在反应过程中生成的硅和铝被氧化，炉渣中氧化锰和氧化铁被还原，碳单质发生化学反应与物理渗透，因此会出现部分碳和锰的收得率大于 100% 的现象。

5.2 双重关联分析模型的建立与求解

5.2.1 相关性分析

相关系数浅显易懂，并且是反应变量之间关系密切程度的统计指标，因此本文决定采用相关系数的分析方法，寻找影响 C、Mn 两元素收得率的因素。

$$r_{xy} = \frac{s_{xy}}{s_x s_y} \quad (15)$$

其中 r_{xy} 表示样本相关系数， s_{xy} 表示样本协方差， s_x 表示 X 的样本标准差， s_y 表示 y 的样本标准差。下面分别是 s_{xy} 协方差和 s_x 和 s_y 标准差的计算公式。由于是样本协方差和样本标准差，因此分母使用的是 $n-1$ 。

样本协方差 s_{xy} 计算公式：

$$s_{xy} = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{n - 1} \quad (16)$$

样本标准差 s_x 计算公式：

$$s_x = \sqrt{\frac{\sum (x_i - \bar{x})^2}{n - 1}} \quad (17)$$

样本标准差 s_y 计算公式：

$$s_y = \sqrt{\frac{\sum (y_i - \bar{y})^2}{n - 1}} \quad (18)$$

通过上式计算，可得到 C 、 Mn 两元素与其他因素之间的相关系数及显著性，通过筛选 $Sig < 0.05$ 的数据，最终得到如下结果：

	钢水净重	连铸正样 C	连铸正样 Ceq_val	连铸正样 V_val
相关系数	0.85	0.157	0.228	0.191
Sig	0	0.018	0.001	0.004

	连铸正样 Ti_val	低铝硅铁	钒氮合金 (进口)	碳化硅 (55%)
相关系数	0.134	0.81	0.149	-0.177
Sig	0.048	0	0.025	0.007

表 5 C 收得率相关性分析

	钢水净重	连铸正样 Mn	连铸正样 Si	连铸正样 Ceq_val	连铸正样 V_val
相关系数	0.947	0.241	0.188	0.135	0.276
Sig	0	0	0.005	0.042	0

	连铸正样 Ti_val	低铝硅铁	钒氮合金 (进口)	钒铁 (FeV50-B)	碳化硅 (55%)
相关系数	0.24	0.944	0.267	-0.196	-0.231
Sig	0	0	0	0.003	0

表 6 Mn 收得率相关性分析

综上,通过相关性分析,本文初步确定出,影响 C 收得率的因素为:钢水净重、连铸正样 C 、连铸正样 Ceq_val 、连铸正样 V_val 、连铸正样 Ti_val 、低铝硅铁、钒氮合金(进口)、碳化硅(55%)。

影响 Mn 收得率的因素为:钢水净重、连铸正样 Mn 、连铸正样 Si 、连铸正样 Ceq_val 、连铸正样 V_val 、连铸正样 Ti_val 、低铝硅铁、钒氮合金(进口)、钒铁($FeV50-B$)、碳化硅(55%)。

5.2.2 偏相关分析

为了对影响因素进行进一步的准确确定,本文决定在控制其他变量的线性影响的条件下,分析两变量间的相关性,而偏相关分析,正是对当两个变量同时与第三个变量相关时,将第三个变量的影响剔除,只分析另外两个变量之间相关程度的方法.本文意在控制多个变量数,因此需要对各因素做高阶偏相关分析.^[2]

在 3 个变量中,任意两个变量的偏相关系数是在排除其余一个变量影响后计算得到的,即为一阶偏相关系数,一阶偏相关系数计算式为:

$$r_{ijh} = \frac{r_{ij} - r_{ih}r_{jh}}{\sqrt{(1 - r_{ih}^2)(1 - r_{jh}^2)}} \quad (19)$$

式中, r_{ij} 是变量 x_i 与 x_j 的简单相关系数, r_{ih} 是变量 x_j 与 x_h 的简单相关系数, r_{jh} 是变量 x_j 与 x_h 的简单相关系数。

在 4 个变量中,任意两个变量的偏相关系数是在排除其他两个变量影响后计算得到的,即为二阶偏相关系数,二阶偏相关系数计算式为:

$$r_{ij\cdot hm} = \frac{r_{ij\cdot h} - r_{im\cdot h}r_{jm\cdot h}}{\sqrt{(1 - r_{im\cdot h}^2)(1 - r_{jm\cdot h}^2)}} \quad (20)$$

式中, i, j, h, m 分别取 1、2、3、4 的组合.显然,二阶偏相关系数是由一阶偏相关系数求得。

一般地,假设有 k ($k > 2$) 个变量 x_1, x_2, \dots, x_k , 则任意两个变量 x_i 和 x_j 的 g ($g \leq k-2$) 阶样本偏向关系数公式为:

$$r_{ij\cdot l_1 l_2 \dots l_g} = \frac{r_{il_g \cdot l_1 l_2 \dots l_g} - r_{il_g \cdot l_1 l_2 \dots l_{g-1}} r_{jl_g \cdot l_1 l_2 \dots l_g}}{(1 - r_{il_g \cdot l_1 l_2 \dots l_{g-1}}^2)(1 - r_{jl_g \cdot l_1 l_2 \dots l_{g-1}}^2)} \quad (21)$$

一阶偏相关系数可以利用三个变量间两两简单相关系数进行计算,即一阶偏相关系数可以利用零阶偏相关系数进行计算;二阶偏相关系数可以利用四个变量间的一阶偏相关系数进行计算.不失一般性,根据 N 阶偏相关系数计算通式可以看出,任何 N 阶偏相关系数都可以通过 $N-1$ 阶偏相关系数进行计算而得.不难推断出,对于 N 阶偏相关系数,可以利用 $N+2$ 个变量组成的 C_{N+2}^2 组简单相关系数进行运算而得出。

利用上述思想,即可得出 C 、 Mn 两元素与其他因素间的偏相关性,由于篇幅有限,只列出三个与 Mn 元素有关因素的结果图.

相关性				
控制变量			C收得率	钢水净重
连铸正样C & 连铸正样Ceq_val & 连铸正样V_val & 连铸正样Ti_val & 低铝硅铁 & 钒氮合金(进口) & 碳化硅(55%)	C收得率	相关性	1.000	.473
		显著性 (双尾)	.	.000
		自由度	0	211
	钢水净重	相关性	.473	1.000
		显著性 (双尾)	.000	.
		自由度	211	0

图 3 C 收得率与钢水净重

相关性				
控制变量			C收得率	连铸正样C
钢水净重 & 连铸正样Ceq_val & 连铸正样V_val & 连铸正样Ti_val & 低铝硅铁 & 钒氮合金(进口) & 碳化硅(55%)	C收得率	相关性	1.000	.397
		显著性 (双尾)	.	.000
		自由度	0	211
	连铸正样C	相关性	.397	1.000
		显著性 (双尾)	.000	.
		自由度	211	0

图 4 C 收得率与连铸正样 C

相关性				
控制变量			C收得率	碳化硅(55%)
钢水净重 & 钒氮合金(进口) & 低铝硅铁 & 连铸正样Ti_val & 连铸正样V_val & 连铸正样Ceq_val & 连铸正样C	C收得率	相关性	1.000	-.376
		显著性 (双尾)	.	.000
		自由度	0	211
	碳化硅(55%)	相关性	-.376	1.000
		显著性 (双尾)	.000	.
		自由度	211	0

图 5 C 收得率与碳化硅

相关性				
控制变量			Mn收得率	转炉终点Mn
钢水净重 & 转炉终点Si & 连铸正样Ceq_val & 连铸正样V_val & 连铸正样Ti_val & 低铝硅铁 & 钒氮合金(进口) & 钒铁(FeV50-B) & 碳化硅(55%)	Mn收得率	相关性	1.000	-.297
		显著性 (双尾)	.	.000
		自由度	0	207
	转炉终点Mn	相关性	-.297	1.000
		显著性 (双尾)	.000	.
		自由度	207	0

图 6 Mn 收得率与转炉终点

相关性				
控制变量			Mn收得率	钢水净重
连铸正样Mn & 连铸正样Si & 连铸正样Ceq_val & 连铸正样V_val & 连铸正样Ti_val & 低铝硅铁 & 钒氮合金(进口) & 钒铁(FeV50-B) & 碳化硅(55%)	Mn收得率	相关性	1.000	.504
		显著性 (双尾)	.	.000
		自由度	0	208
	钢水净重	相关性	.504	1.000
		显著性 (双尾)	.000	.
		自由度	208	0

图 7 Mn 收得率与钢水净重

相关性				
控制变量			Mn收得率	低铝硅铁
钢水净重 & 连铸正样Ti_val & 连铸正样Mn & 连铸正样V_val & 连铸正样Si & 连铸正样Ceq_val & 钒氮合金(进口) & 钒铁(FeV50-B) & 碳化硅(55%)	Mn收得率	相关性	1.000	.240
		显著性 (双尾)	.	.000
		自由度	0	208
	低铝硅铁	相关性	.240	1.000
		显著性 (双尾)	.000	.
		自由度	208	0

图 8 Mn 收得率与低铝硅铁

通过偏相关分析,本文确定了出影响 C 收得率的因素为: 钢水净重、连铸正样 C 、碳化硅 (55%).

影响 Mn 收得率的因素为: 钢水净重,连铸正样 Mn ,连铸正样 Si ,连铸正样 Ceq_val ,连铸正样 V_val ,连铸正样 Ti_val ,低铝硅铁,钒氮合金 (进口),钒铁 (FeV50-B),碳化硅 (55%).

5.2.3 双重相关对主要因素的确定

通过相关性分析与偏相关分析双重分析, 本文对结果进行对比, 校对, 最终确定出了影响 C 、 Mn 两元素收得率的主要因素.

影响 C 元素收得率的主要因素为: 钢水净重、连铸正样 C 、碳化硅 (55%).

影响 Mn 元素收得率的主要因素为: 钢水净重, 连铸正样 Mn , 连铸正样 Si , 连铸正样 C_{eq_val} , 连铸正样 V_val , 连铸正样 Ti_val , 低铝硅铁, 钒氮合金 (进口), 钒铁 (FeV50-B), 碳化硅 (55%).

六、问题二模型的建立与求解

6.1 收得率预测模型的建立与求解

通过上一问的分析, 本文确定出了影响 C 、 Mn 两元素收得率的主要因素, 将这些因素考虑在内的前提下, 可以首先利用多元线性回归, 对 C 、 Mn 两元素收得率进行初步的预测, 并对模型预测的准确性进行检验, 而后确定后续的改进方案.

6.1.1 多元线性回归预测模型的建立

线性回归主要用于对多变量, 多维度输入拟合单输出的情况. 简单的线性回归的公式如下:

$$\hat{y} = w^T x + b \quad (1)$$

其中 \hat{y} 表示估计的输出的变量、 x 表示输入的变量向量, w 为权重向量, b 为标量表示偏置.

为了衡量估计值与真实值之间的差距, 需要用损失函数来对其进行衡量. 假设输入的 x 向量有 n 个维度, 一共有样本 m 个数据, 则损失函数如下所示:

$$L(y, \hat{y}) = \frac{1}{2m} \sum_{i=1}^m (y_i - \hat{y}_i)^2 \quad (2)$$

其中 y , 表示第 i 个样本的真实值, 表示第 i 个样本根据输入、权重和偏置的值所得的估计值. 公式中的一中的分母中的 $\frac{1}{2m}$ 用来补偿样本数量带来的影响, 2 用来补偿求导后的系数 2.

若将偏置 b 与 x 合并, 则公式 (21) 变形为如下形式:

$$\hat{y} = w^T x' \quad (3)$$

其中 $x' = (1, x_1, x_2, x_3, \dots, x_n)$ 由于次公式方便描述, 后续的 x 都表示 x' .

假设输入的 m 个样本分别为 x'' , y'' .

那么损失函数可以表示为:

$$L = \frac{1}{2m}(Xw - Y)^T(Xw - Y) \quad (4)$$

其中大写的 X 和 Y 为 m 行样本的矩阵形式.

损失函数衡量了真实值与估值之间的差距, 因此当损失函数值越小, 二者差距越小, 目标是求损失函数的最小值.

为了求二者之间的最小值, 考虑到损失函数是关于 w 的二次函数, 因此对损失函数进行求导, 令导数等于 0, 即可求得最小值.

$$\begin{aligned} \frac{\partial L}{\partial w} &= \frac{1}{2m} \frac{\partial (w^T X^T X w - 2w^T X^T Y + Y^T Y)}{\partial w} = 0 \\ \Rightarrow w &= (X^T X)^{-1} X^T Y \end{aligned} \quad (5)$$

上式中, 若 X 为满秩的情况时, 即 $m=n$ 时, 存在 w 使得损失函数为 0, 而当 $m > n$ 时, 一般而言, 很难使得损失函数为 0, 除非样本中存着重重复样本的情况. 简单的最小二乘法的另一个缺点是, 当出现多重共线性的情况时, 上式不稳定, 甚至无法求解逆矩阵.

因此本文在进行线性回归预测之前, 要排除各因素之间多重共线性的干扰, 为了解决这一问题, 可以对上式进行更新, 从中添加对角矩阵:

$$w = (X^T X + \lambda I)^{-1} X^T Y \quad (6)$$

在排除了多重共线性后, 利用上述公式, 本文计算求得出了 C 、 Mn 两元素收得率的预测模型.

	非标准化系数B	标准误差	标准系数	t	Sig.	共线性统计量	
						容差	VIF
(常量)	-0.165	0.032		-5.155	0		
碳化硅 (55%)	-0.008	0	-0.7	-46.087	0	0.314	3.182
钢水净重	-60.4613	12.534	-0.732	-48.236	0	0.315	3.175
连铸正样 C	614.144	13.938	0.481	44.062	0	0.608	1.644

表 7 C 收得率预测

由上表可得 C 元素的收得率预测为:

$$\sigma_C = 614.144\beta_C - 60.4613m - 0.008\gamma_{15} - 0.165 \quad (7)$$

	非标准化系数B	标准误差	标准系数	t	Sig.	共线性统计量	
						容差	VIF
(常量)	0.729	0.051		14.418	0		
钢水净重	-68.002	8.671	-0.094	-7.842	0	0.955	1.047
低铝硅铁	0.005	0.001	0.267	5.633	0	0.06	16.548
连铸正样 Mn	0.62	0	-0.241	-15.432	0	0.559	1.789
钒铁	0.36	0	-0.772	-18.736	0	0.08	12.465
钒氮合金	0.025	0	-0.791	-18.706	0	0.076	13.138

表 8 Mn 收得率预测

由上表可得 Mn 元素的收得率预测为:

$$\sigma_{Mn} = 0.62\beta_C - 68.002m + 0.005\gamma_2 + 0.025\gamma_3 + 0.36\gamma_4 + 0.729 \quad (8)$$

6.1.2 模型的检验

通过随机数列, 本文选取了 20 组数据作为模型检验的参考依据, 这 20 组数据的炉号分别为 7A06646、7A06675、7A06707、7A06717、7A06724、7A06741、7A06742、7A06753、7A06763、7A06769、7A06773、7A06777、7A06791、7A06796、7A06799、7A06809、7A06811、7A06818、7A06861、7A06870。

通过上述模型, 对这 20 组数据中 C 、 Mn 两元素收得率进行预测, 由于篇幅有限, 本文只给出部分数据的预测及误差对比, 如下表所示:

炉号	收得率实际值	收得率预测值	误差	平均误差
7A06777	0.72274	0.5986	17.18%	
7A06742	1.062164	1.1652	9.70%	
...	
7A06717	0.970383	0.8369	13.76%	14.81%
...	
7A06799	0.730227	0.5654	22.57%	
7A06724	0.888186	0.7917	10.86%	

表 9 C 收得率预测及误差分析

炉号	收得率实际值	收得率预测值	误差	平均误差
7A06777	0.912532	0.7353	19.42%	
7A06742	0.872318	0.6838	21.61%	
...	
7A06717	0.973913	0.8338	14.39%	16.99%
...	
7A06799	0.899725	0.6976	22.47%	
7A06724	0.927444	0.99318	99.32%	

表 10 Mn 收得率预测及误差分析




图 9 C 收得率预测及对比




图 10 Mn 收得率预测及对比

根据上表及上图，不难看出，通过线性回归预测，所获得的 C 元素收得率平均预测误差为 14.81%， Mn 元素收得率平均预测误差为 16.99%，误差很大，对于实际的预测根本不适用的，因此需要对模型及算法进行改进，以提高收得率预测的准确率。

6.2 模型与算法的改进

本文首先使用多元线性回归对 C 、 Mn 的收得率进行预测，所得到的结果有较大误差，不能较好的拟合出结果，难以进行实际应用. 之所以出现这种情况，是因为收得率不仅仅与时间有关，同时还与多种因素有关，因此需要选择综合预测类模型进行预测。

对此, 本文决定使用径向基函数神经网络 (RBF) 对 C , Mn 元素的收得率进行预测, 但由于 RBF 神经网络易于陷入局部最优解, 预测偏差较大. 故需要用较强全局搜索能力, 且搜索速度快、效率高的粒子群算法对网络权值进行训练. 最后用训练好的数据对实际 C, Mn 元素的收得率进行预测.

6.2.1 径向基函数神经网络拓扑结构

RBF 神经网络由输入层、隐含层、输出层组成, RBF 网络是针对 BP 神经网络存在的局部最小值和收敛速度慢这两个缺陷而提出的一种多层前向网络. 其拓扑结构如下图所示:




图 11 RBF 神经网络结构

作为隐含层基函数的形式, 最常用的是高斯函数:

$$R_j(x) = \exp\left(-\|x - c_j\|^2 / 2\sigma_j^2\right) \quad j = 1, 2, \dots, p \quad (9)$$

其中: x 是 n 维输入向量; c_j 是第 j 个基函数的中心, 是与 x 具有相同维数的向量; σ_j 是第 j 个神经元的标准化常数, 它决定了该基函数围绕中心点的宽度. 参数 m, n, p 分别为输出层、输入层、隐含层的神经元的个数. 确定了隐含层函数后, RBF 网络输入和输出的之间的关系可表达为:

$$ly_i = \sum_{j=1}^p w_{j,i} \exp\left(-\|x - c_j\|^2 / 2\sigma_j^2\right) \quad i = 1, 2, \dots, m \quad (10)$$

6.2.2 减法聚类算法求 RBF 神经网络聚类中心

RBF 神经网络结构设计是如何针对具体的学习任务, 确定合适的核函数个数 n , 核函数的数据中心 c_i 和扩展宽度 δ_i 在 RBF 网络的学习过程中, 这些参数可以通过在线减法聚类算法和网络学习算法共同获得. 在线减法聚类算法聚类时以所有数据样本作为

可能的聚类中心并计算他们的密度值，密度值以该数据样本到所有其他数据样本的距离和作为度量标准，其形式为

$$P(x(i)) = \frac{1}{1 + \frac{1}{N-1} \sum_{j=1, j \neq i}^N (x(i) - x(j))^T (x(i) - x(j))} \quad (11)$$

其中： $i = 1, 2, \dots, N$; $x(i)$ 为数据集 X 中的数据样本； $X = [x(1), x(2), \dots, x(N)]$ ； N 为数据 X 中的数据样本量。该算法将在线减法聚类算法和 RBF 网络参数学习算法有机地结合，利用在线减法聚类算法能够根据在线数据准确判断实时工况的特性，结合 RBF 神经网络的局部响应的物理特性，准确跟踪实时工况。算法中对网络参数的调整，每次只调整距离实时工况数据 x_k 欧式距离最近的核函数的参数，极大地提高了网络的学习速度。

6.2.3 粒子群优化的 RBF 神经网络模型

在钢水“脱氧合金化”过程中，预测的基本步骤可以归纳为：

1) 将样本数据归一化

$$X_t = \frac{X_t - X_{\min}}{X_{\max} - X_{\min}} \quad (t = 1, 2, \dots, 24) \quad (12)$$

式中： x 为 t 时刻样本数值； X_{\min} 为样本最小值； X_{\max} 为样本最大值。

2) 初始化 RBF 神经网络，使用用减法类聚法算出 RBF 网络的数据中心个数，并进行计算。

3) 将 RBF 神经网络权值视为粒子，初始化粒子的初始位置 X 、速度 V 、惯性权重 ω ，加速度权因子 C_1 、 C_2 。设置最大迭代次数 N 。 $C_1=1.5$ ， $C_2=1.5$ ， $N=1000$ 。

4) 定义适应度函数为

$$E = \frac{\sum_{j=1}^n \left[\sum_{k=1}^m (t_{jk} - y_{jk})^2 \right]}{n} \quad (13)$$

式中： t_{jk} 为目标值； y_{jk} 为输出值； m 为输出的节点数； n 为样本数。根据公式计算每个粒子的适应度函数值，开始迭代。如果当前的适应度函数值小于之前的适应度函数值。用当前位置替代之前的 $P_{best,i}$ ，否则 $P_{best,i}$ 保持不变。

5) 取最小的 $P_{best,i}$ ；和 P_{best} 比较，若小于，则替代原 P_{best} ；否则，原 P_{best} 保持不变。

6) 迭代次数加 1，如果迭代次数达到最大而且误差达到要求则停止迭代，输出为神经网络的最优权值。

7) 用训练好的数据对 C,Mn 元素的收得率进行预测

6.2.4 模型结果及模型的检验

本小节验证基于数据驱动的 RBF 神经网络模型，建立钢水中 C,Mn 元素含量的预测。输入数据为合金料加入量数据和冶炼过程时的出钢数据（转炉重点温度，钢水净重，各种元素转炉终点时含量），输出数据为钢水内 C，Mn 元素的含量值。ELM 网络的训练样本总共为 221 组，测试样本为 20 组，其预测结果和实际值的比较如图所示。

炉号	Mn 实际值	改进后预测值	误差	平均误差
7A06777	0.72274	0.69083	4.42%	6.42%
7A06742	1.062164	1.11231	4.72%	
...	
7A06717	0.970383	0.91012	6.21%	
...	
7A06799	0.730227	0.79425	8.77%	
7A06724	0.888186	0.81745	7.96%	

表 11 C 收得率预测及误差分析

炉号	Mn 实际值	改进后预测值	误差	平均误差
7A06777	0.912532	0.8342	8.58%	8.66%
7A06742	0.872318	0.9552	9.50%	
...	
7A06717	0.973913	0.86525	11.16%	
...	
7A06799	0.899725	0.792516	11.92%	
7A06724	0.927444	0.94721	2.13%	

表 12 Mn 收得率预测及误差分析

根据上表可知，通过粒子群优化的 RBF 神经网络模型预测，所获得的 C 元素收得率平均预测误差为 6.42%， Mn 元素收得率平均预测误差为 8.66%，预测的准确率大幅上升，在结果要求精度不高的场合下，完全可以满足对实际的应用。




图 12 C 收得率预测及对比




图 13 Mn 收得率预测及对比

6.3 改进前后对比




图 14 C 收得率预测对比




图 15 Mn 收得率预测对比

通过上图很明显可以看出，通过粒子群优化的 RBF 神经网络模型预测出的值，要比通过多目标回归预测的值，与实际值的拟合程度更高，证明了本次改进的成功性。

七、问题三模型的建立与求解

7.1 目标优化模型的构建

为了更好的实现降本增效这一环保绿色生产观念，本文在进行铁合金配料比计算时同时考虑了两个不同的指标^[3]。第一，为了判断所冶炼的钢种是否符合钢种实际要求，可以在加入铁合金之后测出各元素在钢水中的含量，并将该含量与钢种规程要求的含量

进行比较,若是比较之后的误差小,则表示此次铁合金的配料比成功,其中,误差的计算公式如下所示:

$$f_{\text{error}}(\vec{x}) = \sum_{j=1}^{N_e} w_j \cdot |Y_j - y_j(\vec{x})| \quad (1)$$

其中, $f_{\text{error}}(\mathbf{x})$ 表示的是在此次冶炼之后钢水中的各元素含量与钢种规程之间的误差, N_e 表示钢水中所含有的元素种类的数目, $y_j(\vec{x})$ 表示钢水中第 j 种元素含量的实际值, 而 Y_j 表示钢种规程中第 j 种元素含量的规定值.

其二, 为降低炼钢成本, 寻找最低成本的铁合金的加入量显得尤为重要. 因为不同的钢种有着不同的配料要求, 因此加入到钢水里面的铁合金的种类和含量均会有所差异, 这就导致在对钢水成分进行调整的时候可以在钢种要求的一定的范围内进行. 而且, 每一种铁合金的价格也是不同的, 因此, 在重多配料方案中肯定会存在一种相对而言即保证了钢种质量又可以降低成本的方案. 因此, 以铁合金成本为另一个目标, 其计算表达式为:

$$f_{\text{cost}}(\vec{x}) = \sum_{i=1}^{N_a} x_i \cdot \text{price}_i \quad (2)$$

其中, $f_{\text{cost}}(x)$ 表示当前炉次所加入的铁合金成本, N_a 表示加入铁合金的种类数, price_i 表示第 i 种铁合金的单价, x_i 表示第 i 种铁合金的加入量. 综上可以得出铁合金加入量优化模型的目标函数, 其形式可描述为:

$$\begin{aligned} \min F(\vec{x}) &= (f_{\text{error}}(\vec{x}), f_{\text{cost}}(\vec{x})) \\ \text{s.t. } x_{d\min} &< x_d < x_{d\max}, d = 1, 2, \dots, 227 \end{aligned} \quad (3)$$

上式中, x 为优化模型的决策变量, 包含了合金加入量和出钢信息. $x_{d\min}$ 和 $x_{d\max}$ 分别第 d 个决策变量的下界和上界, D 为决策变量的个数.

本章构建铁合金加入量多目标优化模型, 主要分为钢水元素软测量、多目标优化和铁合金加入量决策三个阶段.

选择脱氧合金化效果较好的历史炉次数据作为训练样本, 利用神经网络进行建模, 预测得出当前炉次的钢水元素含量, 从而实现钢水元素含量软测量. 由于极端学习机神经网络具有较好的泛化能力和快速给出预测结果等优势, 所以本章利用其对实际转炉炼钢中钢水内的元素含量进行预测.

极端学习机是一种单隐层前馈神经网络, 其网络方程如式所示.

$$\sum_{i=1}^L \beta_i g(w_i \cdot x_j + b_i) = o_j, j = 1, \dots, N \quad (4)$$

其中: $x_j \in R^n$ 和 $o_j \in R$ 分别为输入和输出, w_i 和 b_i 分别是输入权值和输出权值, b_i 为偏置值, N 为样本个数, L 为隐藏神经元层数. 算法开始时 w_i , 和 b_i 的值随机给定, 网络训练的目标是确定输出权值 $\beta = [\beta_1, \beta_2, \dots, \beta_L]$, 最小化下式:

$$f(\beta) = \sum_{j=1}^N \left(\sum_{i=1}^L \beta_i g(w_i \cdot x_j + b_i) - t_j \right)^2 \quad (5)$$

在 RBF 网络中输出权值为 $\beta = \mathbf{H}^T$ 其中

$$\mathbf{H} = \begin{bmatrix} g(w_1, b_1, x_1) & \cdots & g(w_1, b_1, x_N) \\ \vdots & \ddots & \vdots \\ g(w_L, b_L, x_1) & \cdots & g(w_L, b_L, x_N) \end{bmatrix} \quad (6)$$

\mathbf{H}^T 是 H 的伪逆, $\mathbf{T} = [t_1, t_2, \dots, t_N]$ 为目标变量.

7.2 基于粒子群优化的多目标优化模型

在钢种冶炼中, 不仅要使钢水中元素含量满足钢种的规程要求, 又要使加入的铁合金成本尽可能的低, 这是一类典型的多目标优化问题. 考虑到实际生产过程中实时性, 本章采用多目标粒子群优化算法进行求解, 该算法具有快速的求解能力. 一些专家曾提出了一种融合了分解和 Pareto 支配机制的多目标粒子群优化算法 (D^2MOPSO), 首先将多目标优化问题通过一组权重分解为多个单目标优化问题, 采用单目标粒子群进行求解. 其次, D^2MOPSO 结合了进化多目标优化算法中的精英保留机制, 采用外部档案中的个体作为单目标粒子群算法的全局最优个体的候选, 使得粒子更有效的在潜在解区域附近搜索, 避免浪费评价次数. 最后, 同时采用目标空间和决策空间的拥挤距离作为个体的密集程度 [6], 如下所示:

$$CD(p_i) = \left(\sum_{j=1}^{AS} \|p_i, p_j\|_{\Omega}, \sum_{j=1}^{AS} \|F(p_i), F(p_j)\|_{\Delta} \right) \quad (7)$$

其中, AS 为外部档案的大小, p_i 和 p_j 分别是档案中个体 i 和 j 的位置, $CD(p_i)$ 为粒子 i 的拥挤距离向量. 当外部档案的解个数超出预设的最大档案容量时, 采用非支配排序的方式比较档案中个体的拥挤距离向量, 随机选择出非支配等级最低的个体 (决策空间和目标空间的拥挤距离均较小) 从外部档案中移除, 使得算法在目标空间和决策空间均保持良好的收敛性和多样性.

虽然算法从外部档案中选择粒子的全局最优避免了粒子进行无效搜索, 但与此同时, 在一定程度上失去了探索未知区域的机会, 而这些未知区域往往可能存在未知的真实解. 因此, 有必要保持一定的概率使得粒子能前往未知区域进行探索, 以增强种群的探索能力, 避免陷入局部最优. 因此, 本章提出相应的改进算法 (记为 $IM-D^2MOPSO$ [8]): 当粒子在选择全局最优时, 如果在一定概率 p 内, 则选择种群中的个体为全局最优, 否则选择外部档案的个体作为全局最优. 概率 p 的计算方法如下:

$$p = p_{\max} - (p_{\max} - p_{\min}) \cdot \frac{k}{N} \quad (8)$$

其中, p_{\max} 和 p_{\min} 分别是最大和最小概率, k 和 N 分别是当前和最大迭代次数. 可以看出, 概率 p 随着迭代次数 k 的增大而逐渐减小, 保证了后期的开发能力.

7.3 模型的求解

通过利用上述模型, 本文求解出了 5 类钢种的合金配料方案, 并计算出了其所需的成本, 如下表:

	HRB400B	HRB400D	HRB500B	HRB500D	Q345B
氮化钒铁 FeV55N11-A	0	0	12	3	0
低铝硅铁	10	0	0	0	0
钒氮合金 (进口)	0	5	35	65	18
钒铁 (FeV50-A)	0	0	16	2	1
钒铁 (FeV50-B)	0	3.5	15	2.5	1.5
硅铝钙	50	30	49.6	0	0
硅铝合金 FeAl30Si25	40	7.18	0	32	21
硅铝锰合金球	0	0	0	0	50
硅锰面 (硅锰渣)	220	135.6	176.4	0	0
硅铁 (合格块)	60	60	90	1.3	0
硅铁 FeSi75-B	60	0	0	150	0
石油焦增碳剂	60	85	186.5	95	68
锰硅合金 FeMn64Si27	600	0	0	0	0
锰硅合金 FeMn68Si18	1300	1350	1580	1570	1480
碳化硅 (55%)	132	135	0	0	0
硅钙碳脱氧剂	20	10	0	0	0
所需成本	19743.2	16509.06	39005.82	38894.8	19633.3

表 13 合金成本配料优化方案

7.4 模型的检验

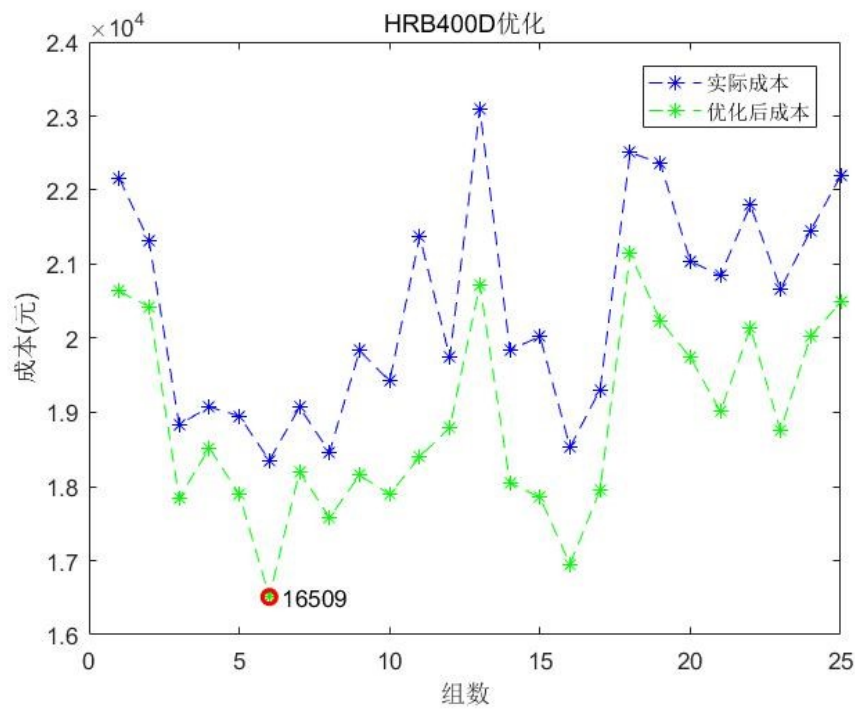


图 16 RBF 神经网络结构

为了对上述所建立的模型进行检验，本文随机挑选了 25 组炉号，并给出了这 25 组炉号优化后的合金配料加入量成本，和实际脱氧合金化时所加入的合金配料成本之间的比较，可以看出优化后的成本整体上低于实际加入的铁合金成本，说明所提模型能在保证钢材质量的同时，有效降低铁合金加入量成本，其所得的决策解可以作为钢厂炼钢生产中的参考，提高生产效益.

八、写给钢厂领导的一封信

尊敬的领导:

您好!我是一名大三的学生,很荣幸借这次比赛的机会给您写信,我们查阅了大量的相关文献以及建立了多个数学模型,来对钢水“脱氧合金化”相关问题进行探究.通过我们的研究结果,我们想向您提几点建议.

(1) 我们通过建立双重相关分析模型,求解得到影响 C 元素收得率的主要因素为:钢水净重、连铸正样 C 、碳化硅 (55%);影响 Mn 元素收得率的主要因素为:钢水净重,连铸正样 Mn ,连铸正样 Si ,连铸正样 C_{eq_val} ,连铸正样 V_val ,连铸正样 Ti_val ,低铝硅铁,钒氮合金 (进口),钒铁 (FeV50-B),碳化硅 (55%).

因此,如果要改变在钢水脱氧合金化 C 、 Mn 元素含量目标值时,上述列举的因素需要重点考量.

(2) 在对 C 、 Mn 两种元素收得率进行预测的过程中,我们首先采用了线性回归进行预测,发现误差值很大,根本无法适用于实际的生产,说明了 C 、 Mn 两种元素的收得率与其相关因素之间,并非只是单纯的线性关系,它一方面与时间有关,另一方面还与其他因素有关.

为此我们建立了基于粒子群优化的 RBF 神经网络模型,对 C 、 Mn 两种元素的收得率进行预测,结果显示,我们对 C 元素的预测误差从 14.81% 降低到 6.42%,对 Mn 元素的预测误差从 16.99% 降低到 8.66%,预测效果显著,精度满足一定的生产要求.如果您有需要可联系相关部门.

(3) 不同的合金配料价格也不尽相同,其选择也发挥着至关重要的作用,一方面要使所炼制的合金各元素含量达到目标区间,另一方面直接影响钢水脱氧合金化的成本.可以说合金配料的选择对炼钢厂的经济与市场影响巨大,不容小觑.

为了探究这一重要问题,我们建立了基于粒子群优化的多目标优化模型,来为炼钢厂提供钢水脱氧合金化成本的优化计算,我们发现目前按照不同元素的固定收得率,或依靠经验值来计算出各中合金的加入量,其基本上是可以保障合金的各目标元素均在要求的目标区间内,但是对脱氧合金化的成本有着波动性的影响.

所以我们还是建议您,为自己炼钢厂的车间尽早引入自动配料模型,在线预测并优化投入合金的种类与数量,以此在保证钢水质量的同时最大限度地降低合金钢的生产成本,避免成本波动对企业的资金流动产生冲击.

以上建议均是在严密的数学模型下提出的.虽然我们的模型并非十分的完美,但是我们相信其发挥的总用也不容小觑.希望我们的建议对您以后的决策有所帮助,同时我们也希望早日看到我国的钢铁企业都能用上脱氧合金化模型,实现自动脱氧合金化的功能.

此致

敬礼!

一名热心的大学生

2019 年 4 月 15 日

九、模型的评价、改进与推广

9.1 模型的评价

9.1.1 模型优点

1. 能够准确控制钢的成分，提高钢质量.
2. 可以稳定操作工艺，避免了传统的人工操作时由于操作工人的不同习惯而造成的随意性.
3. 在满足钢种成分要求的前提下可以实现按合金成本最低加入合金，同时减少了由于钢水成分出格而造成的钢水回炉的概率，降低冶炼成本.
4. 减轻操作工人的劳动强度.
5. 粒子群算法搜索速度快、效率高，算法简单，适合于实值型处理.
6. 双变量相关系数与偏相关相结合使最主要因素的分析更加准确.

9.1.2 模型缺点

1. 在训练样本增多时, RBF 网络的隐层神经元数远远高于前者, 使得 RBF 网络的复杂度大增加, 结构过于庞大, 从而运算量也有所增加.
2. 多元线性回归有时候在回归分析中, 选用何种因子和该因子采用何种表达式只是一种推测, 这影响了某些因子的不可测性, 使得回归分析在某些情况下受到限制.
3. 双变量相关系数结果略片面.

9.2 模型的改进

随着应用范围的扩大, PSO 算法存在早熟收敛、维数灾难、易于陷入局部极值等问题需要解决:

1. 调整 PSO 的参数来平衡算法的全局探测和局部开采能力.
2. 可以设计不同类型的拓扑结构, 来改变粒子学习模式, 从而提高种群的多样性.
3. 将 PSO 和其他优化算法(或策略)相结合, 形成混合 PSO 算法.
4. 可采用小生境技术, 进一步优化 PSO 算法.

9.3 模型的推广

对目前的金属材料研究, 可利用模型规定目标元素含量, 以创造出一种新的、有针对性的钢种, 为建筑等行业提供新鲜的“血液”.

十、参考文献

- [1] 魏春新, 李纪祥, 张越, 王志英. 影响 ANS-OB 精炼合金收得率的因素及对策 [J]. 炼钢, 2003(02):26-29.
- [2] 王世耆. 偏相关系数的计算机算法 [J]. 农业气象, 1981 (4): 32-36
- [3] 张丽君. 基于改进多目标粒子群的铁合金配料优化研究 [D]. 大连理工大学, 2017.
- [4] 王春林, 胡蓓蓓, 冯一鸣, 刘轲轲. 基于径向基神经网络与粒子群算法的双叶片泵多目标优化 [J]. 农业工程学报, 2019, 35(02):25-32.
- [5] 金鑫, 吴旭翔. 基于 RBF 神经网络的非线性野点检测方法 [J]. 控制工程, 2019, 26(01):99-104.
- [6] 何泳. 多目标粒子群算法及其在转炉炼钢中的应用研究 [D]. 大连理工大学, 2016.
- [7] 徐俏. 基于多目标微粒群的转炉合金加入量优化研究 [D]. 大连理工大学, 2010.
- [8] 韩敏, 徐俏, 赵耀, 杨溪林, 林东. 基于微粒群算法的转炉合金加入量多目标优化模型 [J]. 控制与决策, 2010, 25(12):1901-1904.

十一、 附录

附录清单

附录 A 相关性分析

附录 B RBF 神经网络

附录 C 粒子群优化的多目标规划

附录 A 相关性分析

```
data=xlsread('D题附件')
%读取D题相关附件
for i=1:12
x[i]=data(1:200,i);
y[i]=data(1:200,i+12);
c[i]=xcorr(x,y)
%xcorr 计算两个元素间的相关性系数
```

附录 B RBF 神经网络

```
function [ W, sigma, C ] = RBF_training( data, label, n_center_vec )
%RBF_TRAINING Summary of this function goes here
% Detailed explanation goes here

% Using kmeans to find cinter vector
rng(1);
[idx, C] = kmeans(data, n_center_vec);

% Calulate sigma
n_data = size(data,1);

% calculate K
K = zeros(n_center_vec, 1);
for i=1:n_center_vec
K(i) = numel(find(idx == i));
end

% Using knnsearch to find K nearest neighbor points for each center vector
% then calucate sigma
sigma = zeros(n_center_vec, 1);
for i=1:n_center_vec
[n] = knnsearch(data, C(i,:), 'k', K(i));
L2 = (bsxfun(@minus, data(n,:), C(i,:)).^2);
L2 = sum(L2(:));
sigma(i) = sqrt(1/K(i)*L2);
end
```

```

% Calutate weights
% kernel matrix
k_mat = zeros(n_data, n_center_vec);

for i=1:n_center_vec
    r = bsxfun(@minus, data, C(i,:)).^2;
    r = sum(r,2);
    k_mat(:,i) = exp((-r.^2)/(2*sigma(i)^2));
end

W = pinv(k_mat'*k_mat)*k_mat'*label;
end

function [ W, sigma, C ] = lazyRBF_training( data, label, sigma )
%LAZERBF_TRAINING Summary of this function goes here
% Detailed explanation goes here
if nargin < 3
    sigma = 1;
end

n_data = size(data,1);
C = data;

% make kernel matrix
k_mat = zeros(n_data);
for i=1:n_data
    L2 = sum((data - repmat(data(i,:), n_data, 1)).^2, 2);
    k_mat(i,:) = exp(L2'/(2*sigma));
end

W = k_mat\label;
end

function [ y ] = RBF_predict( data, W, sigma, C )
%RBF_PREDICT Summary of this function goes here
% Detailed explanation goes here
n_data = size(data, 1);
n_center_vec = size(C, 1);
if numel(sigma) == 1
    sigma = repmat(sigma, n_center_vec, 1);
end

% kernel matrix
k_mat = zeros(n_data, n_center_vec);
for i=1:n_center_vec
    r = bsxfun(@minus, data, C(i,:)).^2;
    r = sum(r,2);
    k_mat(:,i) = exp((-r.^2)/(2*sigma(i)^2));
end

y = k_mat*W;

```

```
end
```

附录 C 粒子群优化的多目标规划

```
clear all ;
close all ;
clc ;
N = 200 ; % 种群规模
D = 10 ; % 粒子维度
T = 1000 ; % 迭代次数
Xmax = 20 ;
Xmin = -20 ;
C1 = 1.5 ; % 学习因子1
C2 = 1.5 ; % 学习因子2
W = 0.8 ; % 惯性权重
Vmax = 10 ; % 最大飞行速度
Vmin = -10 ; % 最小飞行速度
popx = rand(N,D)*(Xmax-Xmin)+Xmin ; % 初始化粒子群的位置(粒子位置是一个D维向量)
popv = rand(N,D)*(Vmax-Vmin)+Vmin ; % 初始化粒子群的速度(粒子速度是一个D维度向量)
% 初始化每个历史最优粒子
pBest = popx ;
pBestValue = func_fitness(pBest) ;
%初始化全局历史最优粒子
[gBestValue,index] = max(func_fitness(popx)) ;
gBest = popx(index,:) ;
for t=1:T
for i=1:N
% 更新个体的位置和速度
popv(i,:) = W*popv(i,:)+C1*rand*(pBest(i,:)-popx(i,:))+C2*rand*(gBest-popx(i,:)) ;
popx(i,:) = popx(i,:)+popv(i,:) ;
% 边界处理, 超过定义域范围就取该范围极值
index = find(popv(i,:)>Vmax | popv(i,:)<Vmin);
popv(i,index) = rand*(Vmax-Vmin)+Vmin ; %#ok<*FNDSE>
index = find(popx(i,:)>Xmax | popx(i,:)<Xmin);
popx(i,index) = rand*(Xmax-Xmin)+Xmin ;
% 更新粒子历史最优
if func_fitness(popx(i,:))>pBestValue(i)
pBest(i,:) = popx(i,:) ;
pBestValue(i) = func_fitness(popx(i,:));
end
if pBestValue(i) > gBestValue
gBest = pBest(i,:) ;
gBestValue = pBestValue(i) ;
end
end
% 每代最优解对应的目标函数值
tBest(t) = func_objValue(gBest); %#ok<*SAGROW>
end
figure
```



```
plot(tBest);
```
